Klaster analiza muzičkog FMA dataseta

1. Uvod

Sa razvojem digitalnih muzičkih platformi, količina dostupnih audio zapisa značajno je porasla. Organizacija i analiza velikih kolekcija muzike postaje značajan problem u oblasti analize podataka i mašinskog učenja. Jedan od načina za razumevanje strukture takvih datasetova jeste primena metoda **klaster analize**.

Klaster analiza predstavlja grupisanje objekata na osnovu njihove međusobne sličnosti. Za razliku od klasifikacije, kod klasterovanja unapred nisu poznate klase kojima objekti pripadaju, već algoritam pokušava da pronađe prirodne strukture u podacima.

U ovom radu analiziran je **Free Music Archive (FMA)** dataset, koji sadrži veliki broj muzičkih numera opisanih skupom audio karakteristika. Cilj rada je da se ispita da li je moguće identifikovati prirodne grupe pesama na osnovu ovih karakteristika.

2. Skup podataka

Dataset korišćen u ovom radu potiče iz **Free Music Archive (FMA)** kolekcije i sadrži veliki broj muzičkih numera zajedno sa njihovim audio karakteristikama.

Svaka numera opisana je velikim brojem numeričkih atributa koji predstavljaju različite aspekte audio signala. Ove karakteristike uključuju:

- spectral features - karakteristike koje opisuju raspodelu energije u frekvencijskom spektru audio signala
- chroma features - predstavljaju energiju raspoređenu po 12 tonskih klasa (C, C#, D, itd), što je povezano sa harmonijskom strukturom muzike
- tonnetz features - karakteristike koje opisuju harmonske odnose između tonova i koriste se za analizu tonaliteta i akorda
- zero crossing rate - broj prelazaka signala kroz nultu vrednost, što je indikator frekvencijskog sadržaja signala
- statističke karakteristike signala (mean, std, skew, kurtosis)

Ukupan broj atributa u datasetu iznosi približno **430**.

Svaka vrsta u datasetu predstavlja jednu muzičku numeru, dok kolone predstavljaju audio karakteristike.

statistics	kurtosis	kurtosis.1	kurtosis.2	kurtosis.3	kurtosis.4	kurtosis.5	kurtosis.6	kurtosis.7	kurtosis.8	kurtosis.9	...	std.2	std.3	std.4	kurtosis	max	mean	median	min	skew	std
number	0.017346	0.161880	0.267049	0.195536	0.313147	0.466845	0.396237	0.494957	1.194688	1.188263	...	74.968545	100.091151	303.269761	-0.319915	3.372715	28.911998	30.039977	166.541404	-0.727091	35.003713
track_id	-0.019097	-0.037847	-0.048835	-0.024185	-0.032802	-0.038417	-0.027187	-0.032058	-0.056564	-0.057191	...	-0.141131	-0.133501	-0.059690	-0.221969	-0.127921	-0.173563	-0.188062	-0.392561	-0.265786	-0.246072
2	0.208785	0.452356	-0.008555	0.056481	0.079042	0.017714	0.071162	0.152165	0.090281	0.129112	...	-1.552544	-1.143689	-0.572024	-0.266429	0.425792	1.003143	0.870150	-0.392561	-0.369206	0.770907
3	0.044880	0.050426	0.001061	0.106159	0.090459	-0.020375	0.064402	0.046435	-0.012753	0.040790	...	-1.237872	-0.894674	-0.451037	-0.299407	0.463061	0.971065	0.640104	-0.392561	-0.491738	1.058398
5	0.002712	-0.024946	-0.061551	0.021788	0.109330	0.046415	-0.070498	-0.081507	0.063088	0.092087	...	-0.363186	-1.487348	-0.543695	-0.254633	-0.034748	0.010694	-0.065370	-0.392561	-0.335242	0.165893
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
155316	-0.028810	0.023745	0.199114	-0.018593	0.091050	0.147791	-0.030123	0.346143	0.085322	0.203800	...	0.098416	0.762144	0.056725	-0.281159	-1.136849	-0.732270	-0.479453	0.259525	-0.741741	-1.018636
155317	-0.027925	-0.038610	-0.083295	-0.036296	-0.010930	-0.047594	-0.053115	-0.026971	-0.058594	-0.095224	...	0.941418	0.878999	0.117671	-0.294395	-1.009069	-0.660744	-0.494789	0.014993	-0.634142	-0.775193
155318	0.003484	-0.027900	-0.086841	-0.000376	-0.034532	-0.069535	0.084824	0.069962	0.152518	-0.020230	...	-0.236223	0.246839	-0.248285	-0.304666	-0.918558	-0.436897	-0.203398	0.178014	-0.783385	-0.817311
155319	-0.019108	-0.001129	-0.038612	0.005167	-0.015230	-0.096340	-0.062114	0.018809	-0.113108	-0.131244	...	-0.174092	-0.266627	-0.200264	-0.261599	-1.166132	-0.344409	-0.172725	0.422546	-0.458238	-0.736007
155320	0.001538	0.149509	0.052077	-0.019605	-0.036251	0.003663	-0.037717	-0.019464	-0.140764	-0.176211	...	0.012977	-0.186832	-0.079461	-0.086633	2.528836	0.682997	0.026648	0.341036	0.483690	3.534065

Dataset koji je korišćen u analizi sadrži približno **100 000 numera**, što predstavlja veliki skup podataka za klaster analizu.

3. Preprocesiranje podataka

Pre primene algoritama klasterovanja izvršeno je nekoliko koraka preprocesiranja kako bi se poboljšao kvalitet podataka i stabilnost modela.

3.1 Obrada nedostajućih vrednosti

U datasetu se pojavljuju nedostajuće vrednosti (NaN). Umesto uklanjanja svih redova koji sadrže nedostajuće vrednosti, primenjena je metoda **imputacije medijanom**.

Kod ove metode svaka nedostajuća vrednost zamenjuje se medijanom odgovarajuće kolone.

Medijan je izabran jer je robusniji na ekstremne vrednosti u odnosu na aritmetičku sredinu.

U Python implementaciji ovo je realizovano sledećom operacijom:

```
features = features.fillna(features.median())
```

Na ovaj način zadržan je maksimalan broj instanci u datasetu bez gubitka informacija.

3.2 Uklanjanje visoko korelisanih atributa

Veliki broj atributa može dovesti do problema multikolinearnosti i negativno uticati na performanse algoritama klasterovanja.

Zbog toga su uklonjeni atributi koji imaju veoma visoku međusobnu korelaciju.

Korišćen je prag korelacije:

$|r| > 0.95$

Ako dva atributa imaju korelaciju veću od ovog praga, jedan od njih se uklanja iz dataset-a.

3.3 Standardizacija podataka

Pošto atributi imaju različite opsege vrednosti, izvršena je standardizacija korišćenjem StandardScaler metode.

Standardizacija transformiše podatke prema formuli:

$$z = \frac{(x - \mu)}{\sigma}$$

gde je:

- μ srednja vrednost
- σ standardna devijacija

Ova transformacija osigurava da sve karakteristike imaju sličan opseg vrednosti, što je važno za algoritme koji koriste rastojanje kao meru sličnosti.

3.4 Detekcija i uklanjanje outliera

Nakon redukcije dimenzionalnosti primenjen je algoritam **Isolation Forest** za detekciju outliera.

Isolation Forest je algoritam zasnovan na principu da se anomalije lakše izoluje u odnosu na normalne podatke.

Model je treniran sa parametrom:

- contamination = 0.02

što znači da se pretpostavlja da približno **2% podataka predstavlja anomalije**.

Tačke koje su označene kao outlieri uklonjene su iz dataset-a pre primene algoritama klasterovanja.

Ovaj korak je smanjio broj ekstremnih tačaka koje mogu negativno uticati na kvalitet klastera.

4. Redukcija dimenzionalnosti

Dataset koji analiziramo sadrži veliki broj atributa (oko 430). Velika dimenzionalnost može otežati rad algoritama klasterovanja i povećati računarsku složenost.

Zbog toga je primenjena metoda **Principal Component Analysis (PCA)**.

PCA predstavlja tehniku za redukciju dimenzionalnosti koja transformiše originalne atribute u novi skup međusobno ortogonalnih komponenti koje zadržavaju što veći deo ukupne varijanse podataka.

U analizi je prvo izračunata kumulativna objašnjena varijansa kako bi se odredio broj komponenti koji zadržava najveći deo informacija.

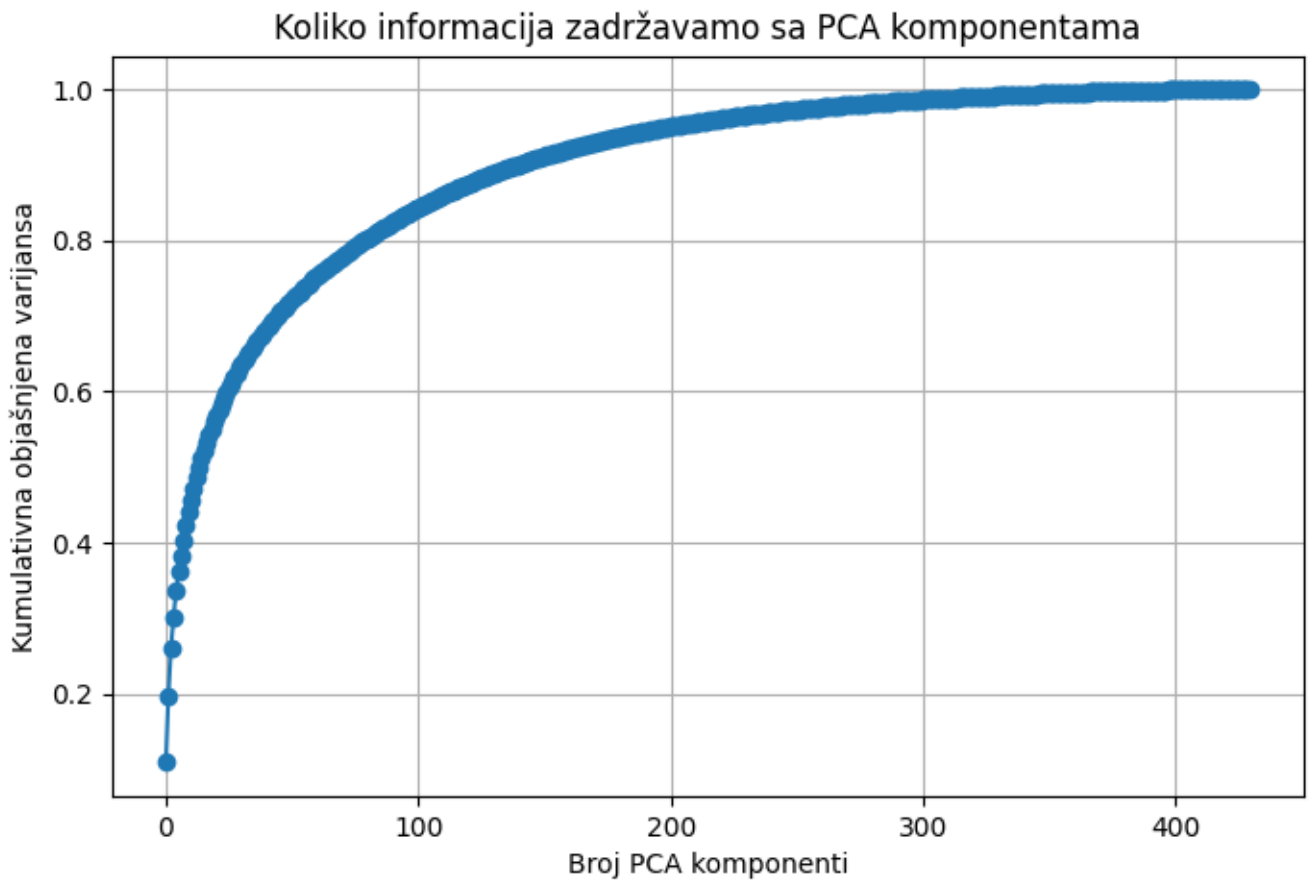

Na osnovu ovog grafa odabrane su tri različite konfiguracije:

- PCA sa 25 komponenti
- PCA sa 60 komponenti
- PCA koji čuva 90% varijanse

Ove tri verzije podataka korišćene su za poređenje performansi različitih algoritama klasterovanja.

5. Vizuelizacija podataka

Pre primene algoritama klasterovanja korisno je vizuelizovati podatke kako bi se dobio intuitivan uvid u njihovu strukturu.

Za vizuelizaciju je korišćena metoda **UMAP (Uniform Manifold Approximation and Projection)** koja omogućava projekciju podataka u prostor manje dimenzionalnosti uz očuvanje lokalne strukture.

Na osnovu vizuelizacije može se primetiti da većina tačaka formira jednu veliku oblast bez jasno odvojenih grupa. Ovo sugeriše da dataset verovatno ne sadrži jaku globalnu klaster strukturu.

6. Algoritmi klasterovanja

U radu je testirano više algoritama klasterovanja kako bi se uporedila njihova sposobnost da pronađu strukturu u podacima.

Korišćeni algoritmi su:

- Agglomerative clustering
- Spectral clustering
- Gaussian Mixture Model
- Birch
- HDBSCAN
- OPTICS

Za procenu kvaliteta klasterovanja korišćene su sledeće metrike:

- Silhouette score
- Calinski-Harabasz indeks

- Davies-Bouldin indeks

U daljoj analizi za poređenje algoritama korišćen je Silhouette koeficijent, jer je najčešće korišćena metrika za procenu kompaktnosti i separacije klastera.

Rezultati su izračunati za različite PCA reprezentacije podataka.

PCA reprezentacija	Algoritam	Silhouette score
PCA25	OPTICS	**0.590082**
PCA60	OPTICS	0.589063
PCA90%	OPTICS	0.565879
PCA25	HDBSCAN	0.499643
PCA60	HDBSCAN	0.471433
PCA90%	HDBSCAN	0.422485
PCA25	Agglomerative	0.354511
PCA60	Agglomerative	0.263176
PCA25	Spectral	0.098991
PCA60	Spectral	0.080112
PCA25	GMM	0.018835
PCA60	Birch	0.018515

Najbolje rezultate ostvaruju OPTICS i HDBSCAN algoritmi, dok GMM i Birch imaju veoma niske silhouette vrednosti, što ukazuje da ne pronalaze značajnu klaster strukturu u datasetu.

7. Analiza rezultata

7.1 Agglomerative clustering

Agglomerative clustering je formirao tri klastera. Međutim, analiza distribucije žanrova unutar ovih klastera pokazuje da su oni prilično heterogeni.

Klaster	Dominantni žanrovi	Udeo
Cluster 0	Experimental	23.8%
	Folk	12.8%
	Rock	12.8%
	Electronic	11.4%
	Classical	9.7%
Cluster 1	Rock	44.2%
	Experimental	20.1%
	Electronic	13.5%
	Hip-Hop	6.2%
	Pop	5.4%

Klaster	Dominantni žanrovi	Udeo
Cluster 2	Electronic	39.0%
	Experimental	20.8%
	Hip-Hop	13.2%
	Rock	11.9%
	Pop	5.6%

To znači da ovaj algoritam nije uspeo da pronađe jasne grupe pesama prema audio karakteristikama.

7.2 HDBSCAN

Algoritam **HDBSCAN** predstavlja density-based metodu koja može detektovati klastere različite gustine i označiti tačke koje ne pripadaju nijednom klasteru kao **noise**.

Rezultati pokazuju da algoritam pronalazi dva klastera, dok veliki broj tačaka ostaje označen kao noise.

Klaster	Dominantni žanrovi	Udeo
Cluster -1 (noise)	Experimental	29.5%
	Electronic	24.0%
	Rock	13.7%
	Instrumental	7.8%
	Pop	6.5%
Cluster 0	Rock	35.4%
	Experimental	17.6%
	Electronic	16.4%
	Hip-Hop	7.2%
	Folk	5.5%
Cluster 1	Old-Time / Historic	**100%**

Jedan od klastera sadrži samo **15 tačaka**, ali analiza žanrova pokazuje da sve one pripadaju istom žanru:

Old-Time / Historic

7.3 OPTICS algoritam

OPTICS (Ordering Points To Identify the Clustering Structure) predstavlja density-based algoritam za klasterovanje podataka. Ovaj algoritam je sličan DBSCAN metodi, ali ima prednost u tome što može da identifikuje klastere različitih gustina.

Za razliku od DBSCAN algoritma koji koristi jedan globalni parametar gustine, OPTICS konstruiše uređen niz tačaka na osnovu njihove dostupnosti (reachability distance). Ovaj niz omogućava identifikaciju klaster strukture u podacima bez potrebe za unapred definisanim pragom gustine.

U ovoj analizi korišćeni su sledeći parametri algoritma:

- min_samples = 5
- xi = 0.05

Rezultati pokazuju da OPTICS algoritam pronalazi nekoliko klastera, dok veliki deo podataka ostaje označen kao **noise**. Ovo je očekivano za density-based algoritme kada dataset ne sadrži jasno odvojene grupe.

OPTICS je u eksperimentima pokazao **najbolje silhouette rezultate** među testiranim algoritmima, posebno za PCA25 reprezentaciju podataka.

Ipak, analiza distribucije žanrova unutar klastera pokazuje da većina klastera i dalje sadrži mešavinu različitih muzičkih žanrova. To ukazuje da dataset ne poseduje snažnu globalnu klaster strukturu.

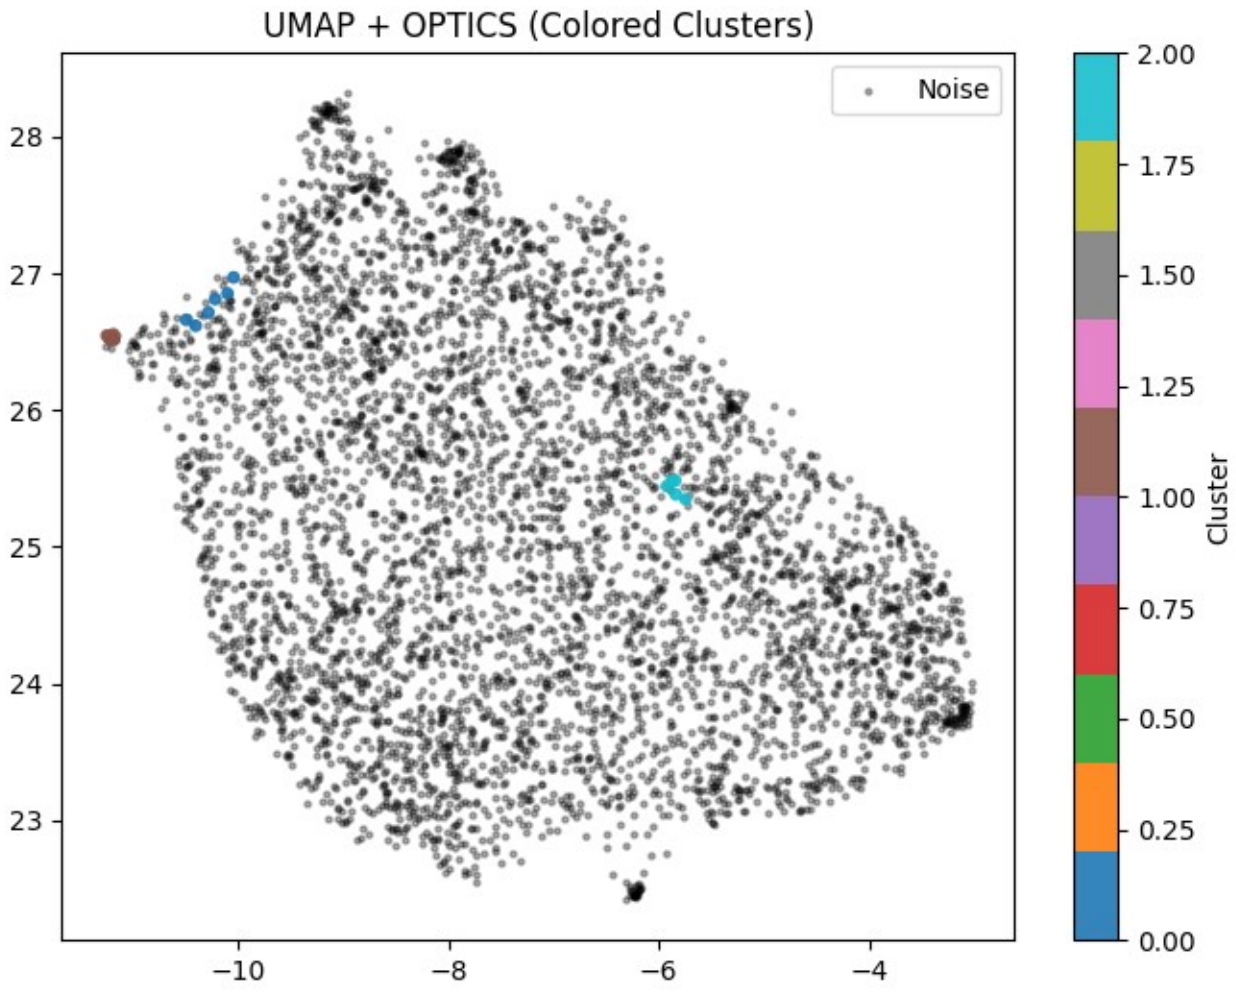

Među testiranim metodama najbolji kvantitativni rezultat ostvario je OPTICS algoritam, dok je HDBSCAN uspeo da identifikuje mali ali vrlo kompaktan klaster koji odgovara žanru Old-Time / Historic.

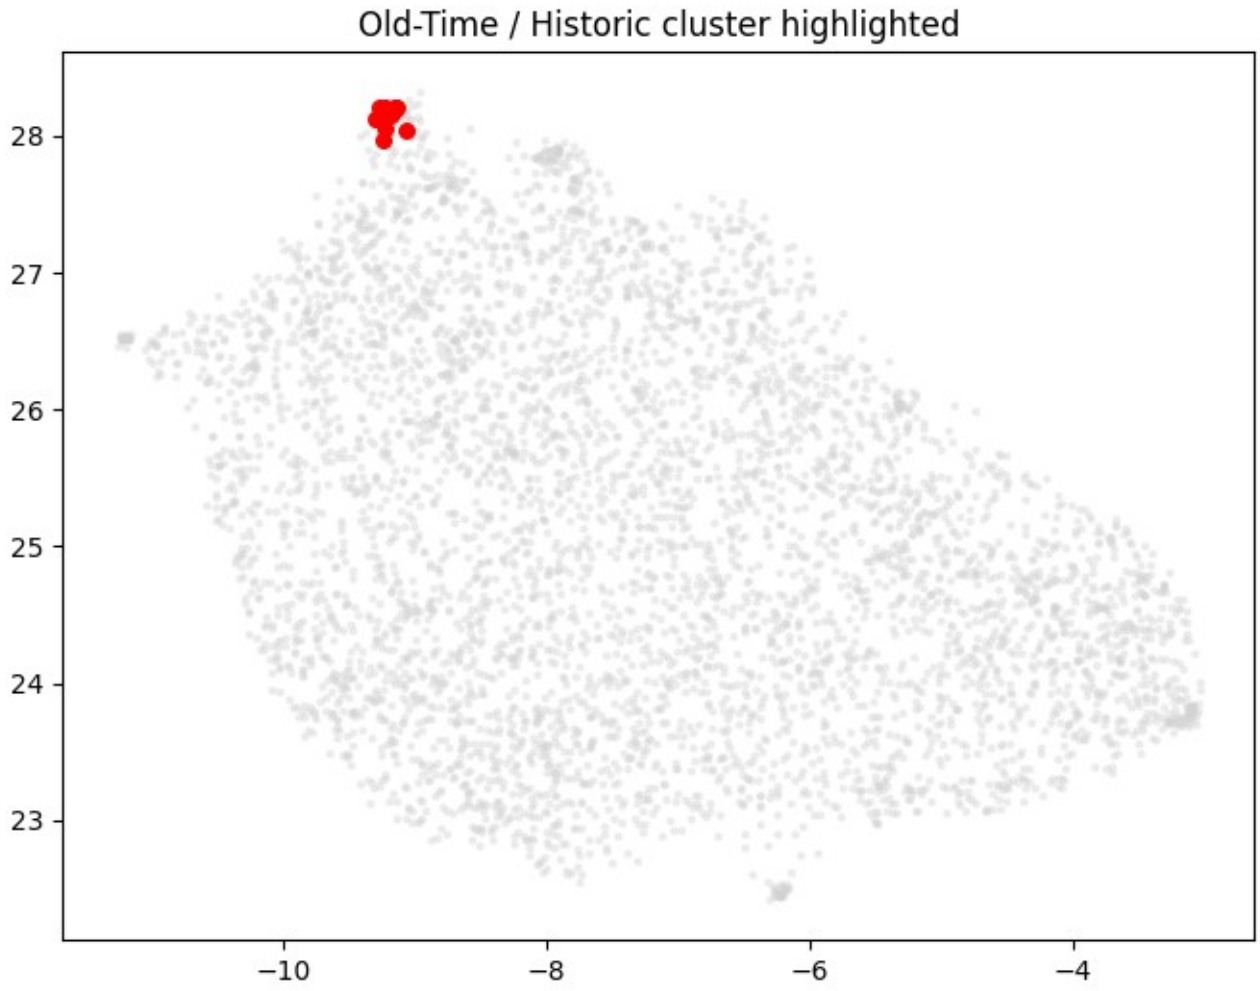

8 Analiza Old-Time klastera

Jedan od zanimljivijih rezultata u analizi predstavlja mali klaster identifikovan pomoću HDBSCAN algoritma, koji odgovara žanru **Old-Time / Historic**. Ovaj klaster sadrži mali broj numera, ali analiza žanrova pokazuje da sve one pripadaju istom muzičkom žanru.

Kako bi se dodatno ispitao ovaj rezultat, izvršena je detaljnija analiza koja uključuje vizuelnu inspekciju i kvantitativnu procenu kompaktnosti klastera.

8.1 Vizuelna analiza

Da bi se bolje razumela pozicija ovih numera u prostoru podataka, izvršena je UMAP projekcija nad celim datasetom. Numere koje pripadaju žanru **Old-Time / Historic** označene su posebnom bojom.

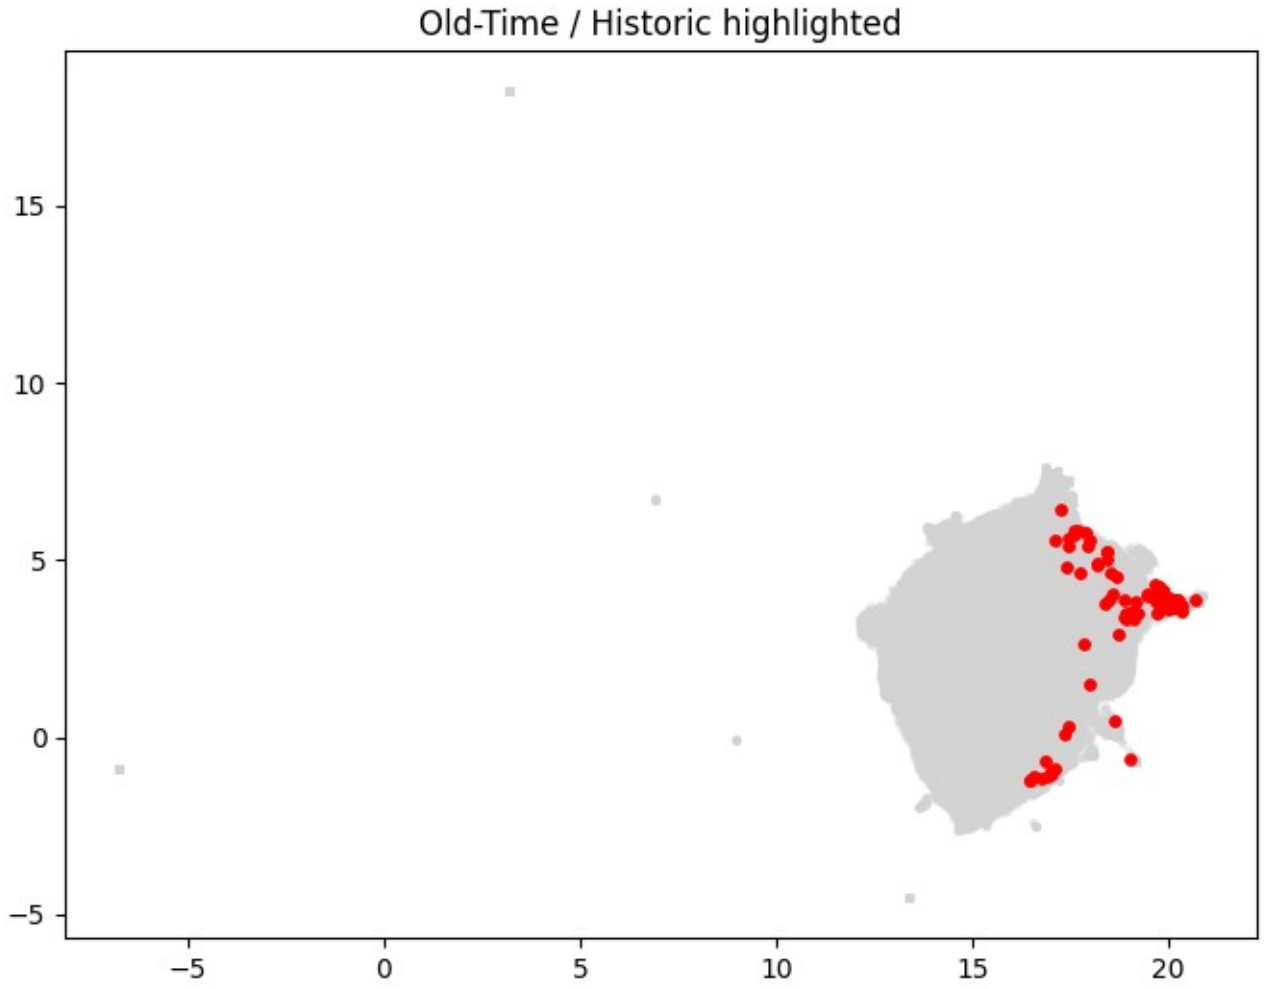

Na osnovu ove vizuelizacije može se primetiti da ove numere ne formiraju potpuno izolovan klaster u globalnom prostoru podataka. Međutim, primećuje se određena lokalna koncentracija tačaka, što ukazuje na postojanje slabije izražene strukture.

Ovaj rezultat sugeriše da iako Old-Time numere nisu potpuno odvojene od ostatka dataset-a, ipak postoji određeni stepen sličnosti između njih.

8.2 Analiza kompaktnosti klastera

Kako bi se dodatno proverilo da li je identifikovani klaster zaista kompaktan, izračunate su prosečne međusobne distance između tačaka unutar klastera.

Rezultati analize su sledeći:

Metod	**Mean distance**
Old-Time cluster	17.50
Random sample	20.44

Odnos ovih vrednosti iznosi približno:

$ratio = 0.86$

Eksperiment je ponovljen više puta kako bi se dobila stabilnija procena, pri čemu je prosečan odnos iznosio 0.8629.

Ovi rezultati pokazuju da su numere u Old-Time klasteru u proseku bliže jedna drugoj nego slučajno izabrane numere iz dataset-a, što potvrđuje postojanje određene lokalne kompaktnosti.

9. Diskusija

Rezultati analize pokazuju da većina algoritama klasterovanja nije uspela da pronađe jasne globalne klastere u ovom datasetu.

Razlog za to može biti nekoliko faktora:

- muzički žanrovi često imaju slične audio karakteristike
- dataset sadrži veliki broj različitih stilova
- audio karakteristike možda nisu dovoljne za jasno razdvajanje žanrova

Međutim, algoritmi zasnovani na gustini poput HDBSCAN i OPTICS pokazali su sposobnost da identifikuju **lokalne strukture** u podacima.

10. Zaključak

U ovom radu analizirana je mogućnost klasterovanja muzičkih numera iz FMA dataset-a na osnovu audio karakteristika.

Testirano je više algoritama klasterovanja i upoređeni su njihovi rezultati.

Analiza je pokazala da:

- globalna klaster struktura nije jasno izražena
- većina algoritama formira heterogene grupe
- algoritmi zasnovani na gustini mogu identifikovati manje lokalne klastere

Posebno je identifikovan mali, ali kompaktan klaster koji odgovara žanru **Old-Time / Historic**.

Ovaj rezultat pokazuje da iako dataset ne sadrži jasne globalne klastere, ipak postoje lokalne strukture koje mogu biti otkrivene odgovarajućim metodama klasterovanja.